

1. 다음 코드들의 출력을 작성하세요. [각 1점]

1-1.

```
array1 = np.array([1, 2, 3])
print(array1.shape)
```

답:

1-2.

```
array2 = np.array([[1, 2, 3], [2, 3, 4]])
print(array2.shape)
```

답:

1-3.

```
array3 = np.array([[1, 2, 3]])
print(array3.shape)
```

답:

2. 다음 코드 중 실행 중 에러가 발생하는 것을 모두 고르세요. [3점]

다음 코드가 먼저 실행되었다고 가정합니다.

```
a = np.arange(24)
```

- ① a.reshape(6, 4)
- ② a.reshape(5, -1)
- ③ a.reshape(-1, 3)
- ④ a.reshape(2, -1, 3)
- ⑤ a.reshape(-1, -1)

3. 다음 코드를 실행한 후, 각 변수의 값을 쓰세요.

[각 2점]

```
import numpy as np

a = np.array([3, 1, 4, 2])

x = np.sort(a)
y = a.sort()
```

3.1. x의 값:

3.2. y의 값:

4. 다음 기능을 수행하는 numpy 함수를 작성하세요.

[각 2점]

다음 코드가 먼저 실행되었다고 가정합니다.

```
import numpy as np
```

4.1. 행렬의 내적 연산을 수행하는 함수:

4.2. 행렬의 전치 행렬을 구하는 함수:

5. 다음 코드를 실행한 결과에 대하여, 물음에 답하세요.

[각 2점]

```
import pandas as pd

s = pd.Series([85, 90, 78], index=["철수", "영희", "민수"], name="점수")
result = s.reset_index()
```

5.1. result의 자료형:

5.2. result의 열 이름:

6. 그림과 같이 타이타닉 데이터셋의 정보를 보고 연길, 채경, 시찬이가 대화를 나누고 있다. 제시한 내용이 옳은 학생만을 있는 대로 고른 것은? [3점]

```
import pandas as pd

titanic_df = pd.read_csv('titanic_train.csv')
titanic_df.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):
#   Column             Non-Null Count  Dtype
---  -
0   PassengerId         891 non-null    int64
1   Survived            891 non-null    int64
2   Pclass              891 non-null    int64
3   Name                891 non-null    str
4   Sex                 891 non-null    str
5   Age                 714 non-null    float64
6   SibSp              891 non-null    int64
7   Parch              891 non-null    int64
8   Ticket              891 non-null    str
9   Fare               891 non-null    float64
10  Cabin              204 non-null    str
11  Embarked            889 non-null    str
dtypes: float64(2), int64(5), str(5)
memory usage: 118.9 KB
```

이 데이터프레임은 890개의 행과 12개의 열로 구성되어 있어.



① 연길

Age 열의 데이터 타입은 float64다.



② 채경

Embarked 열에는 non-null 데이터가 891개 있어.



③ 시찬

④ 연길, 채경

⑤ 채경, 시찬

7. 설명이 맞으면 O, 틀리면 X를 쓰세요. [각 1점]

다음과 같은 DataFrame이 있다고 가정합니다.

```
import pandas as pd

titanic_df = pd.DataFrame({
    "Name": ["A", "B", "C"],
    "Age": [22, 35, 18],
    "Fare": [7.25, 71.83, 8.05]
})
```

- 7.1. titanic_df["Age"]는 "Age" 칼럼을 선택하므로 Series를 반환한다. (O / X)

- 7.2. titanic_df[0]은 첫 번째 행을 선택한다. (O / X)

- 7.3. titanic_df[["Name", "Age"]]는 "Name"과 "Age" 칼럼으로 이루어진 DataFrame을 반환한다. (O / X)

- 7.4. titanic_df[0:2]는 첫 번째 칼럼부터 두 번째 칼럼까지 선택한다. (O / X)

8. 다음은 타이타닉 승객 정보를 저장한 titanic_df의 일부 정보이다. [각 1점]

- 전체 데이터는 891개의 행으로 구성되어 있다.
- Age 칼럼에는 결손 데이터가 존재한다.
- Age 칼럼의 결손 데이터를 평균 나이로 대체하려고 한다.

아래 함수 목록에서 알맞은 함수 또는 표현을 골라 빈칸을 채우세요. 각 항목은 여러 번 사용하거나 사용하지 않아도 됩니다.

함수 및 표현 목록

isna()	head()	sum()
fillna()	mean()	dropna()
sort_values()	value_counts()	reset_index()
max()	astype()	describe()

- 8.1. titanic_df 전체에서 각 값이 결손 데이터인지 확인하고, 그 결과 중 앞의 3개 행만 출력하세요.

titanic_df._____._____

- 8.2. Age 칼럼에 포함된 결손 데이터의 개수를 구하세요.

titanic_df._____._____

- 8.3. Age 칼럼의 결손 데이터를 해당 칼럼의 평균값으로 채우고, 그 결과를 원래 Age 칼럼에 반영하세요.

titanic_df["Age"] = titanic_df["Age"]._____(
titanic_df["Age"]._____)

9. 머신러닝을 통해 분류 예측 모델을 만들고자 한다. 다음 프로세스를 올바른 순서로 나열하세요. [3점]

a. 예측 수행 b. 데이터 세트 분리 c. 평가 d. 모델 학습

답:

10. 다음 코드를 통해 붓꽃 품종을 예측하는 머신러닝 모델을 만들었다. [각 2점]

```
from sklearn.datasets import load_iris
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import accuracy_score

# 데이터 세트 로드
iris = load_iris()
# 의사결정 나무 모델 생성
dt_clf = DecisionTreeClassifier(random_state=11)

# 학습 데이터와 정답(레이블) 분리
train_data = iris.data
train_label = iris.target

# 모델 학습
dt_clf.fit(train_data, train_label)
# 예측 수행 (학습 데이터 사용)
pred = dt_clf.predict(train_data)

# 정확도 출력
print('예측 정확도: ', accuracy_score(train_label, pred))
```

10.1. 위와 같이 모델의 정확도를 구해봤더니 100%가 나왔다. 이와 같은 수치가 나온 이유가 무엇인지 작성하세요.

답:

10.2 모델의 예측 정확도가 100%가 나오는 문제를 해결하기 위해 sklearn.model_selection 모듈에서 사용할 수 있는 함수를 고르세요.

- ① predict_proba()
- ② fit_transform()
- ③ train_test_split()
- ④ accuracy_score()

11. 교차검증에 대한 설명 중 옳지 않은 것을 고르세요. [3점]

- ① 교차검증을 통해 모델의 과적합(Overfitting)문제를 개선할 수 있다.
- ② 교차검증은 학습 데이터셋과 테스트 데이터셋 사이에 검증 데이터셋을 두어 매 반복 마다 학습 데이터셋으로 학습을 진행하고 검증 데이터 셋으로 평가를 진행한다.
- ③ 교차검증은 모델에 사용할 데이터가 부족할 때 도움이 될 수 있다.
- ④ K폴드 교차검증에서 K가 3이면 3개의 세트 중 2개의 세트는 학습에 1개의 세트는 검증에 사용이 된다.
- ⑤ StratifiedKFold는 이렇게 KFold로 분할된 레이블 데이터 세트가 전체 레이블 값의 분포도를 반영하지 못하는 문제를 해결해 준다.
- ⑥ cross_val_score에서 파라미터로 estimator는 성능 평가 지표를 scoring은 예측 성능 평가 점수를 CV는 교차 검증 폴드 수를 의미한다.
- ⑦ cross_val_score은 classifier가 입력되면 내부적으로 StratifiedKFold를 사용한다.

12. 다음과 같이 GridSearchCV를 사용해 DecisionTreeClassifier 모델의 최적의 하이퍼파라미터 조합을 찾고자 한다. 아래와 같이 코드를 작성했을 경우 학습/평가는 총 몇 번 이루어지는가? [4점]

```
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.tree import DecisionTreeClassifier

iris_data = load_iris()
X_train, X_test, y_train, y_test = train_test_split(
    iris_data.data,
    iris_data.target,
    test_size=0.2,
    random_state=121
)

dtree = DecisionTreeClassifier()
parameters = {'max_depth': [3, 4, 5],
              'min_samples_split': [2, 3],
              'min_samples_leaf': [1, 2, 3]}
grid_dtree = GridSearchCV(dtree, param_grid=parameters,
                           cv=5, refit=True)

grid_dtree.fit(X_train, y_train)
```

답:

13. 다음과 같이 원핫 인코딩을 진행했다고 할 때, ㄱ, ㄴ, ㄷ에 들어갈 값을 구하고 [0,1,0,0,0] 은 어떤 연령 분포 레이블에 해당하는지 쓰세요. [각 2점]

연령 분포					
10대	1	0	0	0	0
30대	0	0	1	0	0
20대	0	1	0	0	0
30대	0	ㄱ	ㄴ	0	0
40대	0	0	0	1	0
40대	0	0	0	1	0
50대 이상	0	0	0	0	ㄷ

13.1. ㄱ: ㄴ: ㄷ:

13.2. [0,1,0,0,0] =

14. 피쳐 스케일링과 정규화에 대한 설명 중 옳지 않은 것을 두 개 고르세요. [4점]

- ① 피쳐 스케일링이란 서로 다른 변수의 값 범위를 일정한 수준으로 맞추는 작업이다.
- ② 표준화(standardization)는 원래 값에서 피쳐 x의 평균을 뺀 값을 피쳐 x의 표준편차로 나눈 값으로 계산할 수 있다.
- ③ 학생들 키 데이터를 정규화(Normailzation)하였을 때 데이터의 최솟값은 -1, 최댓값은 1이다.
- ④ Scaler 객체를 이용해 학습 데이터 세트로 fit()과 transform()을 적용하면 테스트 데이터 세트에도 동일하게 fit()과 transform()을 각각 적용해야한다.
- ⑤ 정규화(Normalization)는 기본적으로 표준화보다 (standardization)보다 이상치에 강건하다.